

# Automatische Sprachübersetzung von LATEX-Dokumenten

Name: Hendrik Theede

Matrikelnummer: 221201256 Abgabedatum: 02.12.2025

Betreuer und Gutachter: Prof. Dr. rer. nat. habil. Clemens H. Cap

Universität Rostock

Fakultät für Elektrotechnik und Informatik

Bachelorarbeit am Lehrstuhl für Informations- und Kommunikationsdienste Fakultät für Elektrotechnik und Informatik

# Abstrakt

placeholder

# Inhaltsverzeichnis

1	Einl	eitung 1
	1.1	Hintergrund
	1.2	Anforderungen
2	Prol	blemfälle 3
	2.1	Technische Semantik
		2.1.1 Sonderzeichen
		2.1.2 Leerzeichen
		2.1.3 Zeilenbrüche
		2.1.4 Dokumentenbrüche
	2.2	Sprachliche Semantik
		2.2.1 Ausgangssituation
		2.2.2 Exemplarische Beispiele
	2.3	Spezifischer Technologien
		2.3.1 Kommentare
		2.3.2 Dilemmatische Makros
		2.3.3 TikZ und Layouting
		2.3.4 Quellmehrsprachigkeit
	2.4	Weitere Schwierigkeiten
		2.4.1 Glossare und Nomenklaturen
		2.4.2 Weitere
3		hnologien 11
	3.1	Übersicht
		3.1.1 Auflistung
		3.1.2 Eingrenzung
		3.1.3 Auswertung
	3.2	Einschätzung
	3.3	Fazit
4	Offe	ene Problematiken 12
4	4.1	Verfolgte Ideen         12
	4.2	Gelöste Probleme
	4.3	
		Lessons Learned       12         Fazit       12
	4.4	Tazit
5	Fazi	it 13
	5.1	Zusammenfassung
	5.2	Ausblick
	5.3	Weiteres

6	Eigenständigkeitserklärung	14
Lit	teratur	15
Α	Anhänge	16
	A 1 Fontskalierung auf Webseiten	16

## 1 Einleitung

#### 1.1 Hintergrund

Der erste Satz dieses Werkes befindet sich noch in Arbeit. Vermutlich wird dieser mit einem Wort beginnen, welches seinerseits den Anfangsbuchstaben "a" trägt (bsps. "Ausgehend (von)" oder "Anders (als . . . behaupten)"). Software zur Übersetzung von menschlicher Sprache auf TEX-Quellcode anzuwenden, kann Dokumente erzeugen, welche die TFX-Syntax brechen oder nur zu Teilen und damit unvollständig übersetzt wurden. Mit Hilfe von Google Translate lassen sich wesentliche Gründe ermitteln und welche weitere Folgen aus einem Übersetzungsprozess entstehen können, der nicht von einem LATEX-Dokument ausgeht (mit: TEX, der Programmiersprache für typesetting (Zeichensetzung) von Knuth (1986) sowie der Erweiterung des funktionellen Umfangs durch Lamport (1994)).Bereits einfachste Funktionen dieses Systems können Übersetzungen einfacher Zeichenketten verhindern. Ein Ubersetzen (via Google Translate) von hello wor\textit{ld} liefert nicht Hallo We\textit{lt}, sondern hallo wor\textit{ld}. Abgesehen von der Frage, wo die kursive Hervorhebung im eigentlichen String erfolgen sollte, würden Leser eines kompilierten Dokumentes das Wort "Welt" erkennen.Die beschriebene Zeichenkette wird von TEX als "hello world" dargestellt, in welcher das Wort "world" für einen menschlichen Leser als das englische Wort für "Welt" eindeutig erkennbar ist. Fehlt die Kenntnis über eine der Sprachen (DE,EN) oder ein natürliches Sprachverständnis verliert die Wortkette einen Teil ihrer Bedeutung. Besonders fatal wird dies, wenn das Auslassen von auch nur einem Wort keine Rückschlüsse mehr auf einen größeren Kontext mehr zulässt. \$\mathbb{P}\$robability density function wäre ein denkbarer stilistischer Weg bereits in z.B. einem Folientitel bereits eine Notation für eine Wahrscheinlichkeitsdichtefunktion einzuführen. Hierbei würde der Verlust des Wortes "probability" den stochastischen Kontext aufheben. Der Verlust des Wortes "density" würde einen Kontext innerhalb der Stochastik verändern und ohne das Wort "function" ist fraglich, wovon die Rede ist. Vor allem in größeren Dokumenten könnten hierdurch Logikbrüche entstehen.

Eine Betrachtung eines "Übersetzers" als Konzept veranschaulicht die Problematik auf abstrakterer Ebene. Sollte der Kontext des Dokumentes unbekannt sein, werden sich unausweichlich semantische Fehler einschleichen. Bereits das gezeigte Beispiel könnte für z.B. eine Folie einer Lesung den restlichen Kontext der Seite entfernen und dadurch die Möglichkeit bieten umgangssprachliche Bedeutungen in Wörter zu interpretieren, anstatt einer Mathematischen (bspw. "ungerade" könnte im Englischen "crooked", statt "odd" produzieren). Noch weitere sprachliche Beispiele finden sich schnellig durch Wörter mit zeitlichem/räumlichen Bezug. Der Satz Morgen wird es regnen. könnte ohne das Wort "morgen" als Frage mit unzureichend eingehaltener deutscher Grammatik interpretiert werden. (Wird es regnen?). Hierbei verliert met getroffene Aussage über das Wetter, welches bekanntlicherweise nur schwer vorhergesagt werden kann.

#### 1.2 Anforderungen

Genauso wie das Fehlen einzelner Wörter die sprachliche Bedeutung für einen Menschen brechen kann, treten ähnliche Probleme auch in TEX auf. Einzelne LATEX Makros zu übersetzen kann einen semantischen Verlust für einen TEX Compiler mit sich führen. Als einfaches Beispiel zeigt sich hier die Möglichkeit in bestimmten Fällen eine Dateiendung auszulassen, sollte man ein LATEX Dokument in mehrere TEX Dateien trennen wollen. \include{clock} zu \include{Uhr} zu übersetzen (wie bspw. Google Translate am 06.10.2025) würde nun nicht mehr als \include{clock.tex} interpretiert werden, sondern als \include{Uhr.tex} (dessen Existenz nicht garantierbar ist).

Daher muss nach einer Lösung gesucht werden, welche diese technischen und sprachlichen Hürden überwinden kann. Neben diesen gänzlich technischen Details, darf die Perspektive des Lesers (wörtlich) nicht missachtet bleiben und kein Übersetzungsprozess darf zu einem "verstecktem" Inhalten führen. Diese Verbergungen von evtl. relevanten Informationen resultieren aus verschiedenensten Layouting-Problemen, ähnlich wie bei der Skalierung von Boxen auf Webseiten (Anhang A.1) und ist von den jeweiligen Paaren an Sprachen abhängig (zwischen welchen übersetzt wird). Wünschenswert ist neben vorigen Aspekten auch Möglichkeiten für einen Endnutzer zu finden, welche die Möglichkeit bewahren manuelle Anpassungen vorzunehmen, insofern dies gewünscht ist. Außerdem sollte ein möglichst hoher Support für verschiedene menschliche Sprachen, aber auch verschiedene Laten ein Bon ein Systeme wie Tikz, bzw. pgfplots oder BibTeX innerhalb des Laten nutzbar bleiben.

<sup>&</sup>lt;sup>1</sup>Zwei adjazente Textfelder müssen sich zwangsläufig überlagern, wenn eine dieser Flächen größer werden muss, da z.B. die Textgröße nicht verkleinert werden kann und das Wachstum dieses Textfeldes nur in das Gebiet einer Anderen stattfinden kann. Dies wäre z.B. mit Hilfe von Inhaltsangaben auf Lebensmitteln vorstellbar. Sollten die Wörter der ersten Spalte übersetzt werden und dadurch mehr Textfläche nach rechts benötigen, entstehen beschriebene Überlappungen.

#### 2 Problemfälle

Sprachliche Uneindeutigkeiten können in vielen Sprachen auftreten und dadurch Missverständnisse produzieren (bspw. sarkastische Kommentare oder Mehrdeutigkeiten einzelner Worte). Besonders kritisch sind solche Uneindeutigkeiten jedoch für übersetzende Programme, welche Dokumente in eine andere, menschliche Sprache überführen zu suchen, da hier bereits einzelne missinterpretierte Wörter die TEX Syntax brechen könnten, wodurch nur noch ein unzureichende il der Beschreibung des Dokumentes bestehen bleibt, aus welcher kein echtes Dokument entstehen kann. Was Einhalten der TEX Syntax alleine genügt jedoch nicht, um erwähnte Mehrdeut ten von einzelnen Wörtern zu verhindern, da sie abhängig ihres Kontexts eine andere Übersetzung verlangen. Werterhin können innerhalb von verschiedenen, in Kombination mit TEX genutzten Systeme einzelne "Fehler" entstehen. Ansätze zur Behebung dieser sind jedoch in Tex hen Fällen bereits konzeptionell unmöglich. Hieran anknüpfend existieren einige sehr spezifische sprachliche.

Aus kurzer Nachverfolgung und Einschätzung dieser Probleme werden anschließend konkrete Anforderungen gestellt. Eine Erläuterung dieser Art macht es allerdings unabdingbar eine Software zu nutzen, welche auf das übersetzen spezialisiert ist und nicht von sich aus LATEX oder TEX-konforme Dokumente erwartet. Daher werden Beispiele anhand von Google's Web-Service "Translate" aufgeführt.

#### 2.1 Technische Semantik

#### 2.1.1 Sonderzeichen

Manche menschliche Sprachen beinhalten gelegentlich Zeichen, welche keine direkte Bedeutung tragen und kein Teil auch nur eines Wortes der Sprache sind. Denkbare Beispiele hierfür sind Klammern, die (üblicherweise) für ein impliziert Erwähntes, allerdings nicht vorzeiglich verwendetes Wort genutzt werden. Stilistische Mittel für Texte sind prinzipiell nicht an spezifische Zeichen gebunden und ein Programm kann immer davon ausgehen, dass ein "Tippfehler" entstehen kann. Beispiel 1 zeigt allerdings, wie vereinzelte Zeichenketten produzieren können, welche fälschlich (in diesem Kontext: unerwünscht) übersetzt werden.

**Vermutung** Fraglich ist, warum label nicht erfasst werden sollte, obwohl die folgenden drei Wörter übersetzt werden. Ein String, welcher menschliche Sprache mit Sonderzeichen vermischt, kann dahingehend interpretiert werden, dass diese Sonderzeichen wie Klammern verwendet werden. Seinerseits könnte : also nicht als bekanntes "geteilt" aufgefasst werden, sondern als Klammern. Ersetzt man diese Klammern mit Leerzeichen resultiert aus dem ersten Beispiel \label problem encounter solve und in zweitem Beispiel \section example. Zu sehen ist hier also bereits, dass Google Translate bei einer, wenn man es so interpretieren möchte, "Vernestung" zweiten Grades scheitert, jedoch einfache Vernestungen noch erkennt<sup>2</sup>.

**Takeaway** Teile der  $T_EX$ -Syntax lassen sich anhand von \, {, }, [, ], \$, \$\$ oder \% erkennen und müssten daher ausgeschlossen werden. Anders als in mathematischen Formeln zeigen sich Sonderzeichen jedoch nicht paarweise auf, sodass sie nicht paarweise ignoriert werden können. Man kann sich diese Art von Fehlern wie

<sup>&</sup>lt;sup>2</sup>"Vernestung" meint die Verschachtelung von Klammern

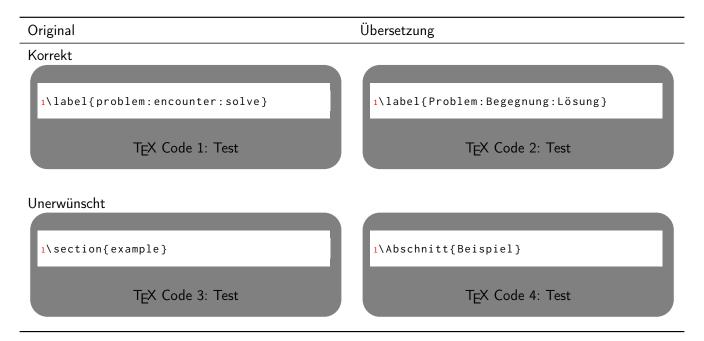


Tabelle 1: Der für einen T<sub>E</sub>X Compiler relevante Befehl label bleibt unverändert, allerdings section wird fälschlicherweise als Abschnitt übersetzt

0-dimensionale Fehler vorstellen, wobei die nullte Dimension hierbei bei einem einzelnen Wort beginnt (welche als Punkte verstanden werden).

#### 2.1.2 Leerzeichen

Dem vorangegangenem Beispiel (zunächst) widersprechend, offenbart ein Auslassen von Zeichen (und dadurch ein Trennen von Worten) eine Vielzahl anderer möglicher Fehler, welche sich glücklicherweise schnell einheitlich beschreiben lassen. Hierunter fallen meist freistehende Worter, welche als Parameter für verschiedene LATEX Umgebungen dienen. Die Übersetzung solcher Parameter kann schnell zu Fehlern in einem TEX-Compiler führen.

**Verdeutlichung** Die Optionen innerhalb eckiger Klammern lassen Whitespace zu. Dies kann jedoch für die Nutzung einiger Funktionen in z.B. wichtigen Paketen wie hyperref dazu führen, dass falsche Wörter übersetzt werden, die ein Kompilieren des Dokumentes verhindern.

Takeaway Teile der TEX-Syntax lassen sich nicht nur anhand der zuvor beschriebenen Zeichenketten erkennen, sondern lassen sich auch in Zeilen wiederfinden. Diese Art von Fehlern bahnt den Weg zu einer Dimension, wodurch nicht nur innerhalb eines Wortes (Punktes), sondern auch zwischen verschiedenen Punkten Fehler entstehen könnten (also innerhalb einer Zeile).

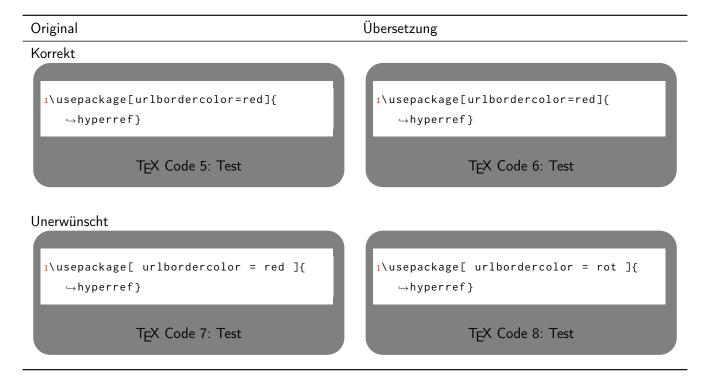


Tabelle 2: Fehler in einem einzeiligen Dokument

#### 2.1.3 Zeilenbrüche

Abstrahiert man nun über einzelne Zeilen hinweg, so wird die folgende Art von Fehlerquelle direkt offensichtlich, sodass sie keiner detaillierten Schilderung mehr bedarf. Sollte man versuchen ein Dokument Zeile nach Zeile zu übersetzen und den Kontext der vorigen Zeile zu ignorieren, so werden schnellig Zeilen übersetzt (obwohl: diese Zeilen nicht übersetzt werden durften, da sie Befehle für TEX beinhalten (siehe: 3)).

Original Übersetzung Korrekt 1This is all \texttt{some} text.\label{ 1Dies ist alles \texttt{irgendein} Text  $\hookrightarrow$  hello} →.\label{hallo} 2The following will only work, if both 2Das Folgende funktioniert nur, wenn  $\hookrightarrow$  the label and reference values ⇒sowohl die Label- als auch die  $\hookrightarrow$ remain the same~\ref{hello}. →Referenzwerte gleich bleiben~\ref{  $\hookrightarrow$  hallo  $\}$ . TFX Code 9: Test T<sub>F</sub>X Code 10: Test Unerwünscht 1\hypersetup{ 1\hypersetup{ urlcolor=red, 2URL-Farbe=rot, urlbordercolor={1 0 0}, 3URL-Rahmenfarbe={1 0 0}, 4} 4} TFX Code 11: Test TFX Code 12: Test

Tabelle 3: Das Übersetzen der hyperref Optionen würde den Kompilier-Prozess scheitern lassen

#### 2.1.4 Dokumentenbrüche

Noch abstrakter wird hier die dritte Dimension erreicht, indem Teile von TEX nicht in einer einzelnen Datei vorliegen müssen, sondern auch in anderen Dateien vorliegen könnten. Diese Tasache wirft eine Vielzahl neuer (und teilweise system-abhängiger) Probleme auf. Hier wurd sich zunächst jedoch nur auf die Fähigkeiten der unveränderten TEX-Engine konzentriert und deren vorgesehene Primitiven (für diesen Zweck).

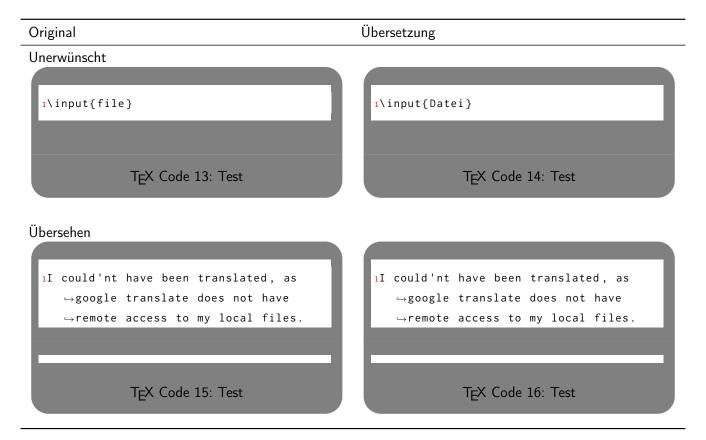


Tabelle 4: Übersetzung in einem include führt zum nicht-Übersetzen einer Datei. Ein zunächst nicht sonderlich "interessant" wirkendes Beispiel

#### 2.2 Sprachliche Semantik

#### 2.2.1 Ausgangssituation

Probleme des vorherigen Teils 2.1 zu verhindern, würde ein Kompilieren eines übersetzten Dokumentes gewähren, als auch keine Inhalte von diesem übersehen. Diese sollten als minimale Anforderung zu sehen sein. Die Fähigkeit alle Inhalte eines LATEX Dokumentes lesen zu können, zeigt sich unausreichend, da das Übersetzen zwischen menschlichen Sprachen<sup>3</sup> je nach Kontext andere Lexeme produzieren muss<sup>4</sup>. Dieser Kontext stammt in

<sup>&</sup>lt;sup>3</sup>Formulierung "menschliche Sprachen": umfasst alle menschlichen Kommunikationswege, auch sprachenunabhängige non-Verbale (bspw. mathematische Notationen) und bildliche Wörter (bspw. chinesische Hanzi, japanische Kanji, theoretisch gesehen auch Gebärdensprachen)

<sup>&</sup>lt;sup>4</sup>Das Übersetzen aus und in Gebärdensprachen ist vorerst nicht im Fokus. Denkbarer Ansatz wäre hier allerdings Dokumente mit Bildern zu erwarten, bei welchen man davon ausgeht, dass diese mit bekannten Methoden der Mustererkennung erkannt und in Wörter (wie sie in den lateinischen Sprachen verwendet werden) überführt werden können und dann maschinell ausgewertet werden können. Hierzu gibt es zahlreiche Technologien (Rastgoo et al. 2025), jedoch beschäftigt dies ein Übersetzen aus einer menschlichen

einem Quellcode aus mehr als nur den rein wörtlichen Inhalten und kann auch aus bestimmten Elementen eines Dokumentes hervorgehen. Ein Bestimmen des *genauen* Kontextes erfordert Kenntnis über diese *bestimmten Elemente* eines Dokumentes, welche alle ihrerseits verschiedenst charakterisiert sein könnten und werden könnten. Es ist nicht garantierbar, dass die Menschheit für die gesamte Zukunft den selben Paradigma folgen wird, mit welchen sie heute Informationen veranschaulicht. Als Beispiel eine Frage: Sahen alle Bilder von Menschen des Steinzeitalters gleich aus?

Vorangegangenes zeigt demnach eine unendliche Menge erwartbarer Probleme. Um innerhalb der Grenzen der Realität zu verweilen, wird sich auf Anwendungsfälle von LATEX für z.B. wissenschaftliche Arbeiten oder Veröffentlichungen konzentriert und inwiefern durch die hierfür benötigten Methoden (bspw. Zitationen, Tabellen, Formeln, Graphiken,...) Kontexte nicht aus der sprachlichen Satzstellung alleine hervorgehen.

#### 2.2.2 Exemplarische Beispiele

Autoren/Titel Ein Autor wird vermutlich innerhalb eines Dokumentes seinen eigenen Namen oder den Titel des jeweiligen Werkes nicht öfters erwähnen, aber aus diesem lassen sich unter Umständen mehr Informationen über den Kontext gewinnen. Handelt es sich um einen bekannten Autoren könnte der Name einen Kontext liefern (welcher jedoch im Vorwege nur als eine Heuristik angesehen werden kann, da der Autor authentifiziert werden muss) oder der Titel trägt den Namen von einer bekannten Methode aus einem wissenschaftlichen Gebiet oder nennt ein solches Gebiet. Denkbare Beispiele umfassen: "[...] of Communication", "Bayesian [...]", "[...] inference [...]" (entnommen aus einigen subject areas von ACM: Transactions on Probabilistic Machine Learning). Vergisst aber ein übersetzendes Programm diese Wörter des Titels an einer kritischen Stelle im Text, so würden fälschliche Übersetzungen entstehen.

#### Dokumenten-interne Verweise

Externe Referenzen Zwar ist das Nutzen einer Technologie wie BibTeX zur

Formeln, Tabellen

Graphiken

#### 2.3 Spezifischer Technologien

Hier wenden wir uns von Problemen einer Übersetzung ab und widmen uns denen eines Lesers. Alle textlichen Inhalte eines Dokumentes zu übersetzen, als auch eine kontextuelle Fachsprache zu bewahren scheint aus abstrakterer Perspektive ausreichen, kann allerdings zu Situationen führen, in welchen Informationen verloren gehen, da diese vom Endnutzer nicht mehr gesehen werden können.

Sprache nach LaTEX und weicht damit von der gegebenen Aufgabenstellung ab. (Obwohl auch hierfür Ansätze existieren: Korzh et al. (2025))

#### 2.3.1 Kommentare

#### Beispiele

**Beschreibungen** Wohingegen sich 2.3.1 nicht mit anderen, in Kommentaren referenzierten, Dateien beschäftigt, soll sich hier auf solche Fälle konzentriert werde.

**Abstrahierung** Hier treffen technische Fehler aus den ersten drei Kategorien (in 2.1.1, 2.1.2 und 2.1.3 geschildert) aufeinander. In die dritte Dimension, also in andere Dateien, wird jedoch (vorerst) nicht traversiert, da auskommentierte Datei-Einbindungen nicht erfasst werden dürften. Ausgehend von **??** wird nun erwartet, dass eine Referenzierung von Dateien erwartet wird, welche sich in Kommentaren verbergen. Dies kann jedoch 2.3.4 beinhalten.

#### 2.3.2 Dilemmatische Makros

Beispiele

Beschreibungen

Abstrahierung

#### 2.3.3 TikZ und Layouting

**Beispiele** 

Beschreibungen

**Abstrahierung** 

#### 2.3.4 Quellmehrsprachigkeit

Beispiele

Beschreibungen

Abstrahierung Quelltexte anderer Quellsprachen (Programmiersprachen) können ihrerseits auf andere Dateien verweisen, oder andere Syntaktik tragen. Das Erkennen dieser ist theoretisch gesehen leicht, jedoch praktisch gesehen schnellig zu übersehen.

# 2.4 Weitere Schwierigkeiten

Kommentare

### 2.4.1 Glossare und Nomenklaturen

Beispiele

Beschreibungen

Abstrahierung

#### 2.4.2 Weitere

Beispiele

Beschreibungen

Abstrahierung

# 3 Technologien

- 3.1 Übersicht
- 3.1.1 Auflistung
- 3.1.2 Eingrenzung
- 3.1.3 Auswertung
- 3.2 Einschätzung
- 3.3 Fazit

## 4 Offene Problematiken

- 4.1 Verfolgte Ideen
- 4.2 Gelöste Probleme
- 4.3 Lessons Learned
- 4.4 Fazit

- 5 Fazit
- 5.1 Zusammenfassung
- 5.2 Ausblick
- 5.3 Weiteres

6	<b>Eigenst</b>	ändig	keitserk	lärung
U	Ligerist	anuig	NCILSCI N	iai ang

_	_	_		
habe. Dazu habe i benutzten Werken	ich keine außer den inhaltlich und wört	von mir angegebenen :lich entnommenen St	tändig angefertigt und oh Hilfsmitteln und Quellen ellen habe ich als solche en gedruckten Exemplaren	verwendet und die den kenntlich gemacht. Ich

Rostock, den 02.12.2025

Hendrik Theede

## Literatur

- Knuth, D. E. (1986), The TeXbook, ISBN: 9780201134476, Addison-Wesley Professional.
- Korzh, D., Tarasov, D., Iudin, A., Karimov, E., Skripkin, M., Kuzmin, N., Kuznetsov, A., Rogov, O. Y. & Oseledets, I. (2025), 'Speech-to-latex: New models and datasets for converting spoken equations and sentences', https://doi.org/10.48550/arXiv.2508.03542 (last Access: 06.10.2025).
- Lamport, L. (1994), LaTeX: A Document Preparation System, 2nd Edition, ISBN: 9780201529838, Addison-Wesley Professional. available at: https://www.latex-project.org/help/books/tlc3-digital-chapter-samples.pdf (last Access: 04.10.2025).
- Rastgoo, R., Kiani, K. & Escalera, S. (2025), 'Sign language recognition: A deep survey', https://doi.org/10.1016/j.eswa.2020.113794 (last Access: 06.10.2025).

## A Anhänge

#### A.1 Fontskalierung auf Webseiten

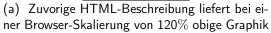
Beispielsweise produziert die folgende HTML-Notation bei einer Skalierung im Browser von 120 Prozent (Abbildung 2a) und 50 Prozent (Abbildung 2b) jeweilig zwei verschiedene PDF (unter welchen nur Zweitere alle textlichen Inhalte offenbart). Ähnliches kann auch innerhalb T<sub>F</sub>X geschehen, sollte

```
<html>
    <head>
        <title>Example</title>
        <style>
            /*formatting options are: none and black*/
                font-size:13em;
                height:50%;
            }
            /*formatting option: none = no background, black, courier*/
                font-family: 'Courier New', Courier, monospace;
            /*formatting option: black = black background, white, serif*/
            .t#black{
                background-color:black;
                color:white;
                margin-top: -2em;
        </style>
    </head>
    <body>
        <div class="t" id="none">Test</div>
        <div class="t" id="black">Test2</div>
    </body>
</html>
```

Abbildung 1: HTML-Beschreibung einer Webseite mit zwei Textflächen

Abbildung 2: Um die Dokumente von der restlichen Papierfläche abzugrenzen wurden schwarze Rahmen mittels TikZ hinzugefügt.







(b) Zuvorige HTML-Beschreibung liefert bei einer Browser-Skalierung von 50% obige Graphik