

Automatische Sprachübersetzung von LATEX-Dokumenten

Name: Hendrik Theede

Matrikelnummer: 221201256 Abgabedatum: 02.12.2025

Betreuer und Gutachter: Prof. Dr. rer. nat. habil. Clemens H. Cap

Universität Rostock

Fakultät für Elektrotechnik und Informatik

Abstrakt

placeholder

Inhaltsverzeichnis

1	Einl	eitung		1
	1.1	Hinter	grund	1
	1.2	Anford	lerungen	2
2	Pro	blemfäl	le	3
	2.1	Strukt	ur	3
		2.1.1	Klassifizierung	3
		2.1.2	Beschreibung	3
	2.2	Transla	ative	4
		2.2.1	Unbekannte Wörter	4
		2.2.2	Auszulassende Wörter	4
		2.2.3	Neuartige Satzarten	5
		2.2.4	Größere Sprachstrukturen	6
	2.3	Techni	ische Probleme	6
		2.3.1	Hilfsdateien	6
		2.3.2	Unerreichbare Informationen	8
		2.3.3	Figuren und Tabellen	9
		2.3.4	Literaturverzeichnisse	9
		2.3.5	Category Codes	9
	2.4	Spezifi	ischer Technologien	9
		2.4.1	Kommentare	9
		2.4.2	Dilemmatische Makros	10
		2.4.3	TikZ und Layouting	10
		2.4.4	Quellmehrsprachigkeit	10
	2.5	Sprach	lliche Schwierigkeiten	10
		2.5.1	Glossare und Nomenklaturen	10
		2.5.2	Weitere	11
3	Eige	enständ	ligkeitserklärung	12
Lit	teratı	ur		13
Α	Anh	änge		14
		_	calierung auf Webseiten	14

1 Einleitung

1.1 Hintergrund

Der erste Satz dieses Werkes befindet sich noch in Arbeit. Vermutlich wird dieser mit einem Wort beginnen, welches seinerseits den Anfangsbuchstaben "a" trägt (bsps. "Ausgehend (von)" oder "Anders (als ... behaupten)").

Herkömmliche Software zur Übersetzung von menschlicher Sprache auf TFX-Quellcode anzuwenden, erzeugt schnell Dokumente, welche entweder nicht vollständig übersetzt wurden oder sich nicht mehr kompilieren lassen. Mit Hilfe von Google Translate lassen sich wesentliche Gründe hierfür finden und wie sich diese äußern. Beispielsweise führt eine Übersetzung von hello wor\textit{ld} nicht zu Hallo We\textit{lt}, sondern zu hallo wor\textit{ld}. Abgesehen von der Frage, wo die kursive Hervorhebung im eigentlichen String erfolgen soll, werden Leser eines kompilierten Dokumentes das Wort "Welt" erkennen. Zuvor beschriebene Zeichenkette wird von TEX zu "hello world" aufgelöst, in welcher das Wort "world" für einen menschlichen Leser als das englische Wort für "Welt" erkenntlich bleibt. Fehlt die Kenntnis über eine der Sprachen (DE,EN), würde einem monolingualen Leser Teil der Wortkette geraubt werden. Selbstverständlich sind die Wörter "world" und "Welt" einander sehr nahe und auch eine Formulierung der Art "Hallo Welt" lässt Vermutungen gegenüber eines größeren Kontexts zu. Anders wäre dies, wenn das Auslassen von auch nur einem Wort keine Rückschlüsse mehr auf einen größeren Kontext mehr zulässt. \$\mathbb{P}\\$robability density function wäre ein denkbarer stilistischer Weg bereits in z.B. einem Folientitel bereits eine Notation für eine Wahrscheinlichkeitsdichtefunktion einzuführen. Hierbei würde der Verlust des Wortes "probability" den stochastischen Kontext aufheben. Der Verlust des Wortes "density" würde einen Kontext innerhalb der Stochastik verändern und ohne das Wort "function" ist fraglich, wovon die Rede ist. Vor allem in größeren Dokumenten könnten hierdurch Logikbrüche entstehen.

Eine Betrachtung eines "Übersetzers" als Konzept veranschaulicht die Problematik auf abstrakterer Ebene. Sollte der Kontext des Dokumentes unbekannt sein, werden sich unausweichlich semantische Fehler einschleichen. Bereits das gezeigte Beispiel könnte für z.B. eine Folie einer Lesung den restlichen Kontext der Seite entfernen und dadurch die Möglichkeit bieten umgangssprachliche Bedeutungen in Wörter zu interpretieren, anstatt einer Mathematischen (bspw. "ungerade" könnte im Englischen "crooked", statt "odd" produzieren). Noch weitere sprachliche Beispiele finden sich schnellig durch Wörter mit zeitlichem/räumlichen Bezug. Der Satz Morgen wird es regnen. könnte ohne das Wort "morgen" als Frage mit unzureichend eingehaltener deutscher Grammatik interpretiert werden. (Wird es regnen?). Hierbei verliert man eine getroffene Aussage über das Wetter, welches bekanntlicherweise nur schwer vorhergesagt werden kann.

1.2 Anforderungen

Genauso wie das Fehlen einzelner Wörter die sprachliche Bedeutung für einen Menschen brechen kann, treten ähnliche Probleme auch in TEX auf. Einzelne LATEX Makros nicht zu übersetzen ist unbedeutend, da sie ihre Bedeutung für einen TEX Compiler behalten. Alleine einzelne Wörter eines Makros zu übersetzen kann dazu führen, dass größere Inhalte (im Sinne: Menge an Worten) nicht mehr in einem kompilierten Dokument vorzufinden sind, was auf eine Fähigkeit von TEX zurückführbar ist. Die Möglichkeit in bestimmten Fällen eine Dateiendung auszulassen, führt beim Einbinden von anderen .tex Dateien in einem TEX Dokument zu fehlerhaften/fehlenden Ressourcenangaben. \include{clock} zu \include{Uhr} zu übersetzen (wie bspw. Google Translate am 06.10.2025) würde nun nicht mehr zu \include{clock.tex} aufgelöst werden, sondern zu \include{Uhr.tex} (bei welchem nicht davon auszugehen ist, dass diese Datei zur Kompilierzeit im System zwingend vorliegt).

Daher muss nach einer Lösung gesucht werden, welche diese technischen und sprachlichen Hürden überwinden kann. Neben solchen rein technischen Details, darf die Perspektive des Lesers (wörtlich) nicht missachtet bleiben und keine Übersetzungsprozesse dürfen zu versteckten Inhalten im Dokument führen. Diese Verbergung resultiert aus verschiedenensten Layouting-Problemen, ähnlich wie bei der Skalierung von Boxen auf Webseiten (Anhang A.1) und ist abhängig von einzelnen Sprachen dazu in der Lage unbemerkt verdeckte textliche Inhalte zu provozieren. Wünschenswert ist neben vorigen Aspekten auch Möglichkeiten für den Endnutzer zu erlauben, sollte dieser spezielle Übersetzungen oder Kontexte für einige Wörter wünschen, welche jedoch nicht aus dem Dokument selbst hervorgehen. Außerdem sollte ein möglichst hoher Support für sowohl verschiedene menschliche Sprachen, aber auch verschiedene LATEX-Pakete gegeben sein, wobei Letzteres nur ein Bonus ist, sollten Systeme wie TikZ, bzw. pgfplots oder BibTEX innerhalb LATEX (zusammen mit TEX) nutzbar bleiben.

¹Zwei adjazente Textfelder müssen sich zwangsläufig überlagern, wenn eines unabdingbar größer werden muss, da z.B. die Textgröße nicht verkleinert werden kann und das Wachstum eines Textfeldes nur in das Gebiet eines Anderen stattfinden kann. Dies wäre z.B. mit Hilfe von Inhaltsangaben auf Lebensmitteln vorstellbar. Sollten diese Wörter übersetzt werden und dadurch mehr Textfläche nach rechts benötigen, würden sie in den tabellarischen Bereich der eigentlichen quantitativen Angaben des z.B. Brennwertes, der Makro- sowie der Mikronährstoffe, hereinragen, wodurch das Risiko besteht, dass diese verdeckt werden.

2 Problemfälle

Eine einzige, feste TEX-Syntax existiert theoretisch gesehen nicht, wie ein späterer Paragraph aufzeigen wird. Die Fähigkeit jegliche erdenkliche Zeichenkette (gegeben: diese ist auf einem Rechner darstellbar, siehe: Unicode Consortium (2025)) sorgt zunächst für eine unendliche Menge an testbaren Problemen. Da es unmöglich ist eine unendliche Menge an Testfällen abzudecken, wird zunächst nur die vorgesehene LATEX (bzw. TEX Syntax nach Knuth (1986)) betrachtet und die bereits rein innerhalb dieser schnellig auffallenden Fehler aufgezeigt, welche durch fälschlich übersetzte Zeichenketten entstehen könnten.

2.1 Struktur

2.1.1 Klassifizierung

Für spätere Testzwecke wurden die verschiedenen Problemfälle in einzelne Kategorien getrennt. Eine solche Kategorisierung ist technisch gesehen nicht zwingend, soll allerdings zur Verbesserung einer späteren Übersicht dienen. Die Einteilung konzentriert sich vorrangig auf die Komplexität des Problemes und in einer Reihenfolge, in welcher sie auch bei der Nutzung von TEX für ein beliebiges Dokument auftreten könnten. Hierbei seien direkte Probleme zunächst eher simple und technisch leicht zu behebende Probleme, welche sich durch ein einheitliches Vorgehen beheben lassen könnten. Zudem beschränkt man sich hier nur auf den benötigten Zugriff auf eine einzelne Datei. Indirekte Probleme formen potentielle Schwierigkeiten, da sie einen Zugriff auf weitere Dateien benötigen, da sie von einer Ausgangsdatei referenziert werden. Technisch gesehen sind sie jedoch auch durch einheitliche Paradigma zu bewältigen. Daher werden sie im Kapitel 2.2 zusammengefasst und fortan als "simple Probleme" bezeichnet. "Fortgeschrittene Probleme" beziehen sich auf Probleme, welche sich paradigmatisch lösen lassen, aber zusätzliches Vorwissen verlangen. Dieses Vorwissen lässt sich bei diesen Problemfällen jedoch ermitteln, da der Entstehungsweg dieses Wissens nachvollziehbar ist. "Speziellere Probleme" umfassen Probleme, welche sich nicht ohne Vorkenntnis des tatsächlichen Dokumentes beheben lassen. Nach diesen wird zudem noch auf ein paar rein sprachliche Schwierigkeiten eingegangen, welche unter Anderem zu solchen speziellen Problemen führen könnten.

2.1.2 Beschreibung

Jeder Problemfall wird zunächst durch ein Beispiel demonstriert², danach wörtlich in einer Beschreibung erläutert und wird abschließend abstrahiert und versucht auf konkrete TEX Primitiven zurückgeführt zu werden. Die fortgeschritteneren Probleme bedürfen teilweise mehreren Beispielen zur Beschreibung, lassen sich jedoch auf ähnliche Äußerungen zurückführen. Einführende Beispiele werden in der Form ausführbarer Code wird zu ausführbarer Code übersetzt, aber ausführbarer Code zu fehlerhafter Code³ (1-dimensional). Einige Beispiele benötigen mitunter eine 2-dimensional der Jenstellung, da sie mehrere Zeilen Quellcode umfassen und werden tabellarisch nebeneinander gestellt. Einige Probleme auf höherer Abstraktionsebene lassen sich aller-

²welche aus einem Test mit Hilfe von Google Translate in Firefox durchgeführt wurden (Oktober 2025)

³, Code" bezieht sich in beiden Fällen auf TEX-Quelltexte

dings nur schwierig veranschaulichen, wodurch Beispiele sich teils wieder auf Schilderungen von Situationen berufen, um diese Übersicht übersichtlich zu halten.

2.2 Translative

2.2.1 Unbekannte Wörter

\label{problem:encounter:solve} wird zu \label{Problem:Begegnung:Lösung} übersetzt, aber \section{example} zu \Abschnitt{Beispiel}.

Beschreibung

Abstrahierung Teile der TEX-Syntax lassen sich anhand von \, {, }, [,], \$, \$\$ oder \% erkennen und müssten daher ausgeschlossen werden. Man kann sich diese Art von Fehlern wie 0-dimensionale Fehler vorstellen, wobei die nullte Dimension hierbei bei einem einzelnen Wort beginnt (welche als Punkte zu verstehen sind).

2.2.2 Auszulassende Wörter

\begin{myenvironment}[fontsize=red] wird zu \begin{myenvironment}[fontsize=red] übersetzt,
aber \begin{myenvironment}[fontsize = red] zu \begin{myenvironment}[fontsize = rot].

Beschreibung

Abstrahierung Teile der TEX-Syntax lassen sich nicht nur anhand der zuvor beschriebenen Zeichenketten erkennen, sondern lassen sich auch in Zeilen wiederfinden. Diese Art von Fehlern bahnt den Weg zu einer Dimension, wodurch nicht nur innerhalb eines Wortes (Punktes), sondern auch zwischen verschiedenen Punkten Fehler entstehen könnten (also innerhalb einer Zeile).

2.2.3 Neuartige Satzarten

```
Original
                                                Übersetzung
 Beispiel 1
                                              1 Dies ist alles \texttt{irgendein} Text.
This is all \texttt{some} text.
                                              2 \label{hallo}
2 \label{hello}
                                              3 Das Folgende funktioniert nur, wenn sowohl
3 The following will only work, if both the
                                                     die Label- als auch die Referenzwerte
     label and reference values remain the
                                                     gleich bleiben~\ref{hallo}.
     same~\ref{hello}.
 Beispiel 2
                                              1 \hypersetup{
1 \hypersetup{
                                              2 URL-Farbe=rot,
     urlcolor=red,
                                              3 URL-Rahmenfarbe={1 0 0},
     urlbordercolor={1 0 0},
4 }
```

Tabelle 1: Beispiel für eine Zeile, welche übersetzt werden darf

Beschreibung

Abstrahierung Teile der T_EX-Syntax lassen sich nicht nur anhand von einzelnen Zeilen oder Zeichenketten erkennen, sondern könnten sich auch in verschiedenen Zeilen wiederfinden lassen. Diese Art von Fehlern kann 2-dimensional betrachtet werden, wodurch Fehler auch zwischen Zeilen entstehen können.

2.2.4 Größere Sprachstrukturen

Original	Übersetzung			
Datei x				
\input{file}	<pre>1 \input{Datei}</pre>			
$Datei\ y$				
I could'nt have been translated, as google translate does not have remote access to my local files.	I could'nt have been translated, as google translate does not have remote access to my local files.			
% This file doesn't need to be translated and couldn't have been, at least in the current way of demonstration.	2 % This file doesn't need to be translated and couldn't have been, at least in the current way of demonstration.			
•	3 % Thus the left/right version of this text have to be the exact same.			

Tabelle 2: Beispiel für eine übersehene Datei

Beispiel

Beschreibung Die Übersetzung von Datei x, welche Datei y via input oder include führt zwar dazu, dass Datei x übersetzt wird, aber Datei y nicht.

Abstrahierung Teile der T_EX-Syntax müssen nicht zwingend in einer Datei vorliegen, sondern könnten auch in verschiedenen Dateien integriert sein. Die Klassifizierung simpler Probleme gelangt in T_EX hier bereits in der dritten Dimension an, weswegen sich fortan bereits mit "fortgeschrittenen" Problemen beschäftigt werden muss (welche sich Teils über mehrere "Dimensionen" erstrecken). Eine vierte Dimension existiert physikalisch nicht, ist jedoch mathematisch formulierbar⁴ und äußert sich in diesem Kontext auf eine Erhöhung von Laufzeitkomplexitäten.

2.3 Technische Probleme

2.3.1 Hilfsdateien

2.3.1.1 Struktur dieses Abschnittes Eine Datei nutzt ein Literaturverzeichnis (BibTEX), pdfTEX (\pdfcomment{}), \footnote, ein Inhaltsverzeichnis, ein Glossar,

⁴physikalisch: die vierte Dimension ist die Zeit, wenn man eine nicht-euklidische 3-dimensionale Bewegung verlangt (Teleportation)

2.3.1.2 Beispielliste

Inhaltsverzeichnisse, Abbildungsverzeichnisse, Tabellenlisten

Beispiel

Erläuterung Ändern wir den Titel eines Paragraphen oder Abschnittes, dann erfasst dies der TEX Compiler beim ersten Durchlauf. Jedoch der String im Inhaltsverzeichnis kann nur verändert werden, sobald diese Information zu Beginn des nächsten Kompilierungsprozesses in der entsprechenden Hilfsdatei vorliegt (.toc).

2.3.1.2.1 Backrefs

Beispiel Bedarf evtl. einer bildlichen Veranschaulichung. Meint: Inhaltsverzeichnis, Tabelle,... vor einer backwards reference verschiebt die echte Position der (Phantom-) Sektion. Daher muss zunächst bestimmt werden, wo im Dokument eine Referenz auf ein existierendes Label stattfindet, welches vorherig bereits vergeben wurde

Erläuterung Ein Verweis auf einen vorherigen Paragraphen kann nur klickbar verlinkt werden, wenn die Information, an welcher Stelle er sich im Dokument befindet, bereits klar ist. Da nach der Referenz weitere Abschnitte folgen können, welche vorherige Elemente mit variabler Größe verändern könnten, muss zunächst die Größe dieser bestimmt sein und gegenüber dieser kann dann der

Literaturverzeichnisse

Beispiel

Erläuterung

PDF Funktionen

Beispiel

Erläuterung

"footnotes"

Beispiel

Erläuterung

2.3.1.3 Abstrahiertes Problem Falls auf Hilfsdateien zugegriffen wird, ist das mehrfache Kompilieren eines $\mbox{ \begin{tikzpicture} \begin{tik$

2.3.2 Unerreichbare Informationen

Original	Übersetzung			
Dokument				
<pre>1 \documentclass{standalone}</pre>	<pre>1 \documentclass{standalone}</pre>			
<pre>2 \usepackage{natbib}</pre>	<pre>2 \usepackage{natbib}</pre>			
3 \bibliographystyle{agsm}	<pre>3 \bibliographystyle{agsm}</pre>			
4 \begin{document}	4 \begin{document}			
5 ~\cite{salomon_c} %Kapitel 5	5 ~\cite{salomon_c} %Kapitel 5			
6 refers to character arrays as a string.	6 bezeichnet Zeichenarrays als Zeichenfolge.			
<pre>7 \bibliography{example_original.bib}</pre>	<pre>7 \bibliography{example_original.bib}</pre>			
<pre>8 \end{document}</pre>	<pre>8 \end{document}</pre>			

Bibliothek

```
1 % Bad Citation, as the title is missing. 1 % Falsche Zitierung, da der Titel fehlt.
                                                Alle notwendigen Informationen finden
     All necessary information can be
     garnered by accessing the book behind
                                                   Sie im Buch hinter der ISBN.
     the isbn.
                                              2 @misc{salomon_c,
2 @misc{salomon_c,
                                              3 author={{Prof. Dr.-Ing. habil. Ralf
     author={{Prof. Dr.-Ing. habil. Ralf
                                                    Salomon }},
     Salomon }},
                                              4 \text{ year} = \{2013\},
     year = {2013},
                                              5 title={Siehe ISBN: 978-3-00-042684-1},
     title={Siehe ISBN: 978-3-00-042684-1}, 6 }
6 }
```

Tabelle 3: Beispiel für einen verpassten literarischen Kontext

Beispiele

Beschreibungen Ein Dokument erwähnt ein Werk, in welchem es um die C-Programmierung geht. Rein aus den im System vorliegenden Dateien ist kein Kontext für das Wort "String" erkennbar, sodass ein Zugriff auf eine externe Ressource unabdingbar ist.

Abstrahierung Einfache Cloud-Architektur. Ein Client möchte auf ein beliebiges Wissen einer Webseite (bzw. dem Server und den beanspruchten Speicherplätzen in einem (beliebigen) Rechenzentrum⁵ zugreifen).

2.3.3 Figuren und Tabellen

Beispiele

Beschreibungen

Abstrahierung

2.3.4 Literaturverzeichnisse

Beispiele

Beschreibungen BibTEX erlaubt es an vielerlei Stelle eigene Strings in einer kompilierten TEX-Datei zu verbergen.

Abstrahierung

2.3.5 Category Codes

Beispiele

Beschreibungen

Abstrahierung

2.4 Spezifischer Technologien

Mitunter NP-schwer.

2.4.1 Kommentare

Beispiele

Beschreibungen Wohingegen sich 2.4.1 nicht mit anderen, in Kommentaren referenzierten, Dateien beschäftigt, soll sich hier auf solche Fälle konzentriert werde.

⁵Hierbei ist nicht von Festspeicher zu reden. Aus Sicherheitsgründen sei davon auszugehen, dass sich die physischen Adressen des wissensrepräsentierenden Speichers regelmäßig und unvorhersehbar ändern

Abstrahierung Hier treffen simple Fehler aus den ersten drei Kategorien (in 2.2.1, 2.2.2 und 2.2.3 geschildert) aufeinander. In die dritte Dimension, also in andere Dateien, wird jedoch (vorerst) nicht traversiert, da auskommentierte Datei-Einbindungen nicht erfasst werden dürften. Ausgehend von **??** wird nun erwartet, dass eine Referenzierung von Dateien erwartet wird, welche sich in Kommentaren verbergen. Dies kann jedoch 2.4.4 beinhalten.

2.4.2 Dilemmatische Makros

Beispiele

Beschreibungen

Abstrahierung

2.4.3 TikZ und Layouting

Beispiele

Beschreibungen

Abstrahierung

2.4.4 Quellmehrsprachigkeit

Beispiele

Beschreibungen

Abstrahierung Quelltexte anderer Quellsprachen (Programmiersprachen) können ihrerseits auf andere Dateien verweisen, oder andere Syntaktik tragen. Das Erkennen dieser ist theoretisch gesehen leicht, jedoch praktisch gesehen schnellig zu übersehen.

2.5 Sprachliche Schwierigkeiten

2.5.1 Glossare und Nomenklaturen

Beispiele

Beschreibungen

Abstrahierung

2.5.2 Weitere

Beispiele

Beschreibungen

Abstrahierung

2				•		
3	Eigens	tandı	IØKP	itseri	Klar	บเทช
•		carra	٠,,,			٠۶

Literatur

Knuth, D. E. (1986), The TeXbook, ISBN: 9780201134476, Addison-Wesley Professional.

Unicode Consortium (2025), 'Unicode: The world standard for text and emoji', https://home.unicode.org/(last Access: 06.10.2025).

A Anhänge

A.1 Fontskalierung auf Webseiten

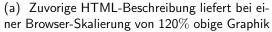
Beispielsweise produziert die folgende HTML-Notation bei einer Skalierung im Browser von 120 Prozent (Abbildung 2a) und 50 Prozent (Abbildung 2b) jeweilig zwei verschiedene PDF (unter welchen nur Zweitere alle textlichen Inhalte offenbart). Ähnliches kann auch innerhalb TFX geschehen, sollte

```
<html>
    <head>
        <title>Example</title>
        <style>
            /*formatting options are: none and black*/
                font-size:13em;
                height:50%;
            /*formatting option: none = no background, black, courier*/
                font-family: 'Courier New', Courier, monospace;
            /*formatting option: black = black background, white, serif*/
            .t#black{
                background-color:black;
                color:white;
                margin-top: -2em;
        </style>
    </head>
    <body>
        <div class="t" id="none">Test</div>
        <div class="t" id="black">Test2</div>
    </body>
</html>
```

Abbildung 1: HTML-Beschreibung einer Webseite mit zwei Textflächen

Abbildung 2: Um die Dokumente von der restlichen Papierfläche abzugrenzen wurden schwarze Rahmen mittels TikZ hinzugefügt.







(b) Zuvorige HTML-Beschreibung liefert bei einer Browser-Skalierung von 50% obige Graphik